

Laboratorio 6: Análisis de redes sociales en YouTube

CC3084 – Data Science, Semestre II 2026

Anthony Lou Schwank – 23410

Isabella Obando – 23074

Francisco Martinez – 23617

Repositorio del proyecto:

<https://github.com/anthonylouschwank/Lab6-DS>

1. Introducción

El objetivo del laboratorio fue estudiar la estructura de participación de usuarios en YouTube a partir de dos conjuntos de datos: `youtube_videos.csv` (293 videos de canales guatemaltecos) y `youtube_comments.csv` (406 comentarios). El trabajo combinó limpieza de datos, análisis exploratorio, construcción y análisis de redes (bipartita autor-video, proyecciones, comunidades, centralidad) y análisis de sentimiento de texto en español. Todo el código está organizado en `src/` (`p1_load_integrate.py` a `p9_sentiment.py`, ejecutables en orden con `python src/run_all.py`), con tablas en `outputs/tables/` y figuras en `outputs/figures/`.

2. Descripción e integración de los datos

Cada fila de `youtube_videos.csv` es un video (llave primaria `video_id`) y cada fila de `youtube_comments.csv` es un comentario principal (llave primaria `comment_id`, con `video_id` como llave foránea y `author_channel_id` como identificador del autor). La relación canal-video es 1 a N, video-comentario es 1 a N, y autor-video es **N a N** –es justamente esta última la que se modela como red bipartita más adelante.

Al integrar ambos conjuntos por `video_id`, el 100 % de los 406 comentarios se asocia correctamente a un video, pero esos comentarios se concentran en solo **19 de los 293 videos (6.5 %)**. No es un error de integración sino del procedimiento de recolección: los comentarios solo se extrajeron para una selección de videos. Este hallazgo condiciona todo el resto del análisis: la red, la concentración de participación y el sentimiento se refieren a esos 19 videos y a los 332 autores que comentaron en ellos, no al corpus completo.

3. Limpieza y preprocesamiento

El diagnóstico de calidad no encontró duplicados (0 `video_id` ni `comment_id` repetidos) y confirmó consistencia total entre identificadores y nombres visibles (todo `channel_id/author_channel_id` mapea a un único nombre). Se identificaron variables inútiles o delicadas: `viewer_rating` (100 % vacía, se descarta), `is_pinned` (constante), `upload_date` y `owner_handle` (redundantes con otras columnas), y `reply_count`, que –como aclara el enunciado– **no identifica a los autores de las respuestas**, por lo que nunca se usó para construir aristas autor-autor.

Los conteos guardados como texto se convirtieron a número (`like_count_text`, 46.6% vacío, interpretado como 0 “me gusta” visibles, el comportamiento normal de la interfaz de YouTube). Se conservaron dos versiones del texto de cada comentario: `texto_original` (intacto, para el análisis de sentimiento) y `texto_limpio`, que aplica minúsculas, elimina URLs, separa menciones y hashtags a columnas propias, convierte emojis a su descripción en español (en vez de borrarlos, porque son la principal señal de sentimiento en comentarios cortos), quita acentos, puntuación y *stopwords* en español. No se lematizó: con comentarios tan cortos, un lematizador ligero podía introducir más errores gramaticales que beneficio. El efecto neto de la limpieza fue modesto: 0 textos originales vacíos, solo 1 texto limpio vacío, y una reducción de 139 a 100 caracteres promedio.

4. Análisis exploratorio

La participación está fuertemente concentrada: un solo video (“*Qué rico come tu diputado*”, canal Quorum) reúne el **39.7%** de los 406 comentarios, y el canal Quorum por sí solo explica el **63.1%**, con solo 11 de los 293 videos del conjunto completo (Figura 1). Las visualizaciones de los 293 videos tienen una distribución muchísimo más sesgada (mínimo 2, mediana 1,175, máximo 8,190,449).




Figura 1: Comentarios por video (los 19 videos con comentarios en la muestra).

Entre popularidad y participación hay una correlación de Spearman positiva y fuerte ($\rho = 0,811$) para esos 19 videos, pero no es monótonica: el video más visto de la submuestra (~304,000 vistas, un video institucional de la Municipalidad) recibió solo 25 comentarios, mientras que el más comentado (161) apenas tiene ~11,800. El tipo de contenido (opinión/humor vs. comunicado institucional) parece importar tanto como el alcance bruto.

Un hallazgo notable del análisis de frecuencias es que buena parte de los bigramas más frecuentes de `texto_limpio` son en realidad **emojis convertidos a texto** (*cara llorando*, *manos aplaudiendo*, *bandera guatemala*, Figura 2): una fracción relevante del “contenido textual” es reacción emotiva breve, no argumento desarrollado. Las palabras sueltas con contenido temático genuino (*pueblo*, *dinero*, *diputados*, *corruptos*) apuntan a crítica político-económica. De los 332 autores, solo **9 comentaron en más de un video** (2.7%); de ellos, 7 comparten audiencia dentro del mismo canal y solo 2 cruzan de canal.




Figura 2: Bigramas más frecuentes en `texto_limpio`: nótese cuántos provienen de emojis.

5. Red bipartita autor-video

Se construyó una red bipartita no dirigida (`networkx`) con dos tipos de nodo: 19 **videos** y 332 **autores**. Existe una arista si el autor comentó en el video, con peso igual al número de comentarios que dejó ahí (agregando repeticiones). El resultado son **351 nodos y 343 aristas** (Figura 3), con 40 aristas de peso mayor a 1. Una arista indica únicamente co-presencia de comentarios: **no** implica que dos autores conectados al mismo video se conozcan o estén de acuerdo, ni que el autor haya visto el video completo, y –siguiendo la aclaración explícita del enunciado– `reply_count` nunca se interpretó como arista, porque no identifica a quién respondió.




Figura 3: Red bipartita completa autor-video (351 nodos, 343 aristas, sin podar).

6. Proyecciones y topología de la red

A partir de la bipartita se construyeron dos proyecciones ponderadas: **autor-autor** (arista si comparten un video, peso = videos compartidos) y **video-video** (arista si comparten un autor, peso = autores compartidos). La primera crece a **332 nodos y 10,732 aristas**: un video con 128 comentaristas genera por sí solo miles de conexiones “todos contra todos”, por lo que su altísima transitividad (0.984) es en gran parte un artefacto de la proyección, no evidencia de un grupo social cohesionado. La segunda, mucho más parca (**19 nodos, 11 aristas**, Figura 4), es más informativa: identifica qué videos comparten audiencia real, y muestra que **9 de los 19 videos quedan totalmente aislados** (ningún autor en común con otro), mientras que los 10 restantes forman una única componente conectada gracias a solo 9 autores puente.




Figura 4: Proyección video-video: 19 nodos, 11 aristas.

La Tabla 1 resume la topología de las tres redes. Las tres comparten la misma fragmentación de fondo (10 componentes), y en la bipartita el 93 % de los nodos tiene grado 1: la enorme mayoría de los autores comentó una sola vez en un solo video. Este aislamiento es *observado*, no necesariamente real: esos autores podrían participar en muchos otros videos fuera de esta muestra de 406 comentarios.

Cuadro 1: Métricas de topología por red.

Red	Nodos	Aristas	Densidad	Componentes	Comp. mayor
Bipartita	351	343	0.0056	10	286 (81.5 %)
Autor-autor	332	10,732	0.1953	10	276 (83.1 %)
Video-video	19	11	0.0643	10	10 (52.6 %)

7. Comunidades

Se aplicó **Louvain ponderado** (`networkx.community.louvain_communities`, semilla fija 42) sobre la proyección video-video, por ser la red más pequeña y la que representa directamente audiencia compartida entre contenidos (la autor-autor, dominada por cliques de proyección, habría redescubierto solo “quién comentó en cuál video”). El algoritmo encontró **12 comunidades** con modularidad $Q = 0.4053$, aunque 9 de ellas son videos aislados sin ninguna arista (comunidades triviales de un nodo). Las tres comunidades no triviales, dentro de la componente de 10 videos, se resumen en la Tabla 2 y se visualizan en la Figura 5.

Cuadro 2: Las tres comunidades principales de la proyección video-video.

Comunidad	Videos	Comentarios	% del total	Tema dominante
1	4	225	55.4 %	Crítica a diputados y corrupción
2	3	84	20.7 %	Reacción a figuras y anuncios de gobierno
3	3	34	8.4 %	Política de telecomunicaciones/mercado




Figura 5: Comunidades de la proyección video-video (Louvain, $Q = 0,4053$).

8. Centralidad y nodos puente

Sobre la bipartita se calcularon grado, fuerza (grado ponderado), intermediación (*betweenness*) y PageRank; se complementó con puntos de articulación (`nx.articulation_points`), que responden con precisión a “si elimino este nodo, ¿se segmenta la red?”. No se usó cercanía por la fragmentación en 10 componentes, donde esa métrica deja de ser comparable.

El resultado matiza el hallazgo del EDA: de los 9 autores con comentarios en más de un video, solo **7 son puntos de articulación reales** (su remoción fragmenta la red); los otros 2 conectan pares de videos que ya comparten otro puente redundante, por lo que quitarlos individualmente no desconecta nada. En el lado de los videos, 15 de los 19 muestran intermediación mayor a 0, pero en su mayoría de forma trivial (son el único camino entre sus propios comentaristas, que no están conectados entre sí de otro modo); solo los que además participan en la componente de 10 conectan audiencias realmente distintas. En conjunto, la mitad de los videos con comentarios permanece unida a la otra mitad gracias, en última instancia, a un núcleo de solo 7 personas.

9. Análisis de sentimiento

Se usó **pysentimiento** con **RoBERTuito**, un modelo tipo RoBERTa preentrenado y afinado sobre tuits en español [3], preferido sobre un léxico simple porque nuestros comentarios son cortos, informales y con emojis convertidos a texto —exactamente el dominio para el que RoBERTuito fue entrenado— y porque capta negación y contexto mejor que sumar polaridad palabra por palabra. El análisis corrió sobre `texto_original`, no sobre `texto_limpio`, para no perder las señales (acentos, mayúsculas, formato del emoji) que el modelo usa.

El sentimiento global es **61.3% negativo, 19.5% neutro y 19.2% positivo** (Figura 6), coherente con el vocabulario de crítica político-económica ya identificado. Pero no es uniforme: como muestra la Figura 7, “*Plan 2032 Ciudad de Guatemala*” (un video institucional de la Municipalidad)

es un outlier claro con **80 % de sentimiento positivo**, mientras que videos de crítica política superan 80 % negativo. Esto sugiere que el sentimiento responde más al *tipo de evento narrado* (denuncia/corrupción vs. anuncio de obra) que a un sesgo generalizado en contra de algún canal en particular –de hecho, otros videos del propio Gobierno de Guatemala caen del lado negativo.




Figura 6: Distribución global de sentimiento (406 comentarios).




Figura 7: Sentimiento por video (videos con al menos 5 comentarios).

10. Limitaciones

Solo el 6.5 % de los videos (19/293) tiene comentarios en la muestra, y no fueron elegidos al azar sino mediante consultas de búsqueda dirigidas (`source_query/source_group`), lo que sobre-representa a un canal de opinión (Quorum explica 63 % de los comentarios) frente al resto del corpus. Las fechas de publicación de los comentarios son relativas (“hace 2 días”) y dependen del momento de la recolección, por lo que no se puede reconstruir una línea de tiempo exacta. Los conteos de vistas y “me gusta” son una fotografía de un único momento, no valores estables. Finalmente, `reply_count` no identifica autores de respuestas, así que toda la red se basa únicamente

en comentarios principales, no en hilos de conversación reales; y buena parte de las métricas de red dependen de un solo video (161/406 comentarios) y de apenas 7 autores puente, por lo que son sensibles a cambios pequeños en esos pocos nodos.

11. Conclusiones

Dentro de esta muestra, la conversación de YouTube alrededor de contenido guatemalteco es estructuralmente fragmentada (la mitad de los videos con comentarios no comparte ningún autor con el resto) pero muy concentrada dentro de su componente principal, con la conectividad entre videos sostenida por muy pocas personas. Es también temáticamente polarizada hacia la crítica político-económica, con un sentimiento global 61.3 % negativo, aunque esa negatividad depende más del *género* del video (denuncia vs. anuncio institucional) que de quién lo publicó. Dado que un solo canal explica el 63 % de los comentarios analizados y que la selección de videos no fue aleatoria, estos resultados deben leerse como una fotografía descriptiva de esta muestra puntual, útil para entender la dinámica de participación dentro de estos 19 videos, y no como evidencia representativa del consumo de YouTube en Guatemala en general.

Referencias

- [1] Hagberg, A., Swart, P., & Chult, D. (2008). Exploring Network Structure, Dynamics, and Function using NetworkX. *Proceedings of the 7th Python in Science Conference (SciPy2008)*.
- [2] Blondel, V. D., Guillaume, J.-L., Lambiotte, R., & Lefebvre, E. (2008). Fast unfolding of communities in large networks. *Journal of Statistical Mechanics*.
- [3] Pérez, J. M., Furman, D. A., Alonso Alemany, L., & Luque, F. (2021). RoBERTuito: a pre-trained language model for social media text in Spanish. *arXiv:2111.09453*.
- [4] Bird, S., Klein, E., & Loper, E. (2009). *Natural Language Processing with Python*. O'Reilly Media.